

# Solução do Problema de Quadrados Mínimos Discretos Utilizando a Decomposição em Valores Singulares (SVD)

João Pedro de Lima e Raymundo Eduardo Pilz

2025-06-23

## 1. Introdução

O método dos mínimos quadrados é uma das ferramentas mais fundamentais da estatística e da análise numérica, sendo utilizado para ajustar modelos a dados experimentais. Sua principal aplicação consiste em encontrar uma função que melhor represente um conjunto de observações, minimizando os erros entre os valores observados e os valores previstos pelo modelo.

Historicamente, o método foi desenvolvido de forma independente por Adrien-Marie Legendre e Carl Friedrich Gauss. Este último, em particular, aplicou a técnica para prever a órbita de corpos celestes, como o asteroide Ceres, a partir de observações incompletas.

O problema de mínimos quadrados pode ser formulado, em termos matriciais, como a busca por um vetor de parâmetros  $\mathbf{x}$  que minimize a norma euclidiana do resíduo:

$$\min_{\mathbf{x}} \|\mathbf{Ax} - \mathbf{b}\|_2$$

onde  $\mathbf{A}$  é a matriz de design e  $\mathbf{b}$  é o vetor de respostas observadas.

Este trabalho tem como foco a resolução desse problema utilizando a Decomposição em Valores Singulares (SVD), destacando suas vantagens numéricas e computacionais em relação a outras abordagens clássicas.

## 2. Fundamentação Teórica

### 2.1 O Problema de Quadrados Mínimos Discretos

Dado um conjunto de observações experimentais representadas por pares ordenados  $(x_i, y_i)$ , com  $i = 1, \dots, n$ , o objetivo é encontrar os parâmetros de um modelo  $f(x, \beta)$  que melhor se ajustem aos dados. O critério de ajuste é baseado na minimização da soma dos quadrados dos resíduos:

$$S(\beta) = \sum_{i=1}^n [y_i - f(x_i, \beta)]^2$$

Em casos simples, como a regressão linear, o modelo assume a forma:

$$f(x, \beta) = \beta_0 + \beta_1 x$$

### 2.2 Alternativas para a Resolução

Existem diferentes métodos para resolver o problema de mínimos quadrados:

- **Equações Normais:**

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

Método rápido, porém sensível a problemas de condicionamento numérico.

- **Decomposição QR:** Boa estabilidade numérica, mas menos robusta que a SVD frente a colinearidade severa.
- **Decomposição SVD:** Extremamente estável numericamente. Recomendada para problemas com colinearidade, dados mal-condicionados ou de posto deficiente.

Além desses, métodos iterativos e regularizados (como Ridge Regression) podem ser utilizados em casos específicos.

### 2.3 A Decomposição SVD

A Decomposição em Valores Singulares expressa qualquer matriz  $A \in \mathbb{R}^{m \times n}$  como o produto:

$$A = U \Sigma V^T$$

Onde:

- $U$  é uma matriz ortogonal de dimensão  $m \times m$ ,
- $\Sigma$  é uma matriz diagonal  $m \times n$  contendo os valores singulares,
- $V$  é uma matriz ortogonal de dimensão  $n \times n$ .

Entre as principais propriedades da SVD, destacam-se:

- Robustez numérica;
- Capacidade de identificar direções de variabilidade dos dados;
- Permite o cálculo da pseudo-inversa de maneira estável.

## 2.4 Condicionamento Numérico e Estabilidade da SVD

O condicionamento numérico de um problema está relacionado à sensibilidade de sua solução em relação a pequenas perturbações nos dados de entrada. No contexto de sistemas lineares e mínimos quadrados, o número de condição da matriz  $\mathbf{A}$  desempenha papel central.

O número de condição  $\kappa(\mathbf{A})$  na norma 2 é definido como:

$$\kappa(\mathbf{A}) = \frac{\sigma_1}{\sigma_r}$$

onde  $\sigma_1$  é o maior valor singular e  $\sigma_r$  é o menor valor singular não nulo de  $\mathbf{A}$ .

Um número de condição alto (muito maior que 1) indica que o problema é mal condicionado, ou seja, pequenas alterações em  $\mathbf{b}$  podem causar grandes mudanças na solução  $\mathbf{x}$ . Isso é comum em problemas com colinearidade entre variáveis ou dados mal escalados.

A SVD permite identificar e lidar com o mal condicionamento, pois:

- Os valores singulares mostram diretamente a escala de variabilidade das direções no espaço de colunas de  $\mathbf{A}$ ;
- Componentes com  $\sigma_i$  muito pequenos podem ser eliminados ou regularizados (por exemplo, com truncamento da SVD ou regressão ridge), melhorando a estabilidade da solução;
- Evita a inversão direta de  $\mathbf{A}^T \mathbf{A}$ , que pode amplificar o erro se  $\mathbf{A}$  for mal condicionada.

Dessa forma, a decomposição SVD é especialmente adequada para resolver o problema de mínimos quadrados com robustez numérica, mesmo quando a matriz  $\mathbf{A}$  é de posto deficiente ou próxima de singular.

## 3. Metodologia

SVD é uma técnica matricial que decompõe uma matriz (real ou complexa) original em três componentes:

- Uma matriz ortogonal  $U$
- Uma matriz diagonal  $\Sigma$
- A transposta da matriz ortogonal  $V$

A representação geral da SVD é dada por:

$$A = U\Sigma V^T$$

Afim de contextualizar a base da construção da SVD, tem-se o **Teorema SVD Geométrico**:

Seja  $A \in \mathbb{R}^{n \times m}$  uma matriz de posto  $r > 0$ . Então, existem  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ , uma base ortonormal  $\{v_1, \dots, v_m\}$  de  $\mathbb{R}^m$  e uma base ortonormal  $\{u_1, \dots, u_n\}$  de  $\mathbb{R}^n$  de modo que

$$Av_i = \begin{cases} \sigma_i u_i, & \text{se } i = 1, \dots, r \\ 0, & \text{se } i = r+1, \dots, m. \end{cases} \quad \text{e} \quad A^T u_i = \begin{cases} \sigma_i v_i, & \text{se } i = 1, \dots, r \\ 0, & \text{se } i = r+1, \dots, n. \end{cases}$$

Em particular,  $v_1, \dots, v_m$  são autovetores de  $A^T A$ ,  $u_1, \dots, u_n$  são autovetores de  $AA^T$ , e  $\sigma_1^2, \dots, \sigma_r^2$  são os autovalores não nulos de  $A^T A$  e  $AA^T$ .

Além disso:

Para cada  $A \in \mathbb{R}^{n \times m}$  de posto  $r$ , existe uma matriz

$$\Sigma = \begin{pmatrix} \hat{\Sigma} & 0 \\ 0 & 0 \end{pmatrix} \in \mathbb{R}^{n \times m},$$

em que  $\hat{\Sigma} = \text{diag}\{\sigma_1, \dots, \sigma_r\}$  e  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ , e existem matrizes ortogonais  $U \in \mathbb{R}^{n \times n}$  e  $V \in \mathbb{R}^{m \times m}$  tais que

$$A = U\Sigma V^T.$$

Para cada  $A \in \mathbb{R}^{n \times m}$  de posto  $r$ , existe uma matriz

$$\Sigma = \begin{pmatrix} \hat{\Sigma} & 0 \\ 0 & 0 \end{pmatrix} \in \mathbb{R}^{n \times m},$$

em que  $\hat{\Sigma} = \text{diag}\{\sigma_1, \dots, \sigma_r\}$  e  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ , e existem matrizes ortogonais  $U \in \mathbb{R}^{n \times n}$  e  $V \in \mathbb{R}^{m \times m}$  tais que

$$A = U\Sigma V^T.$$

Os números  $\sigma_1, \sigma_2, \dots, \sigma_r$  são denominados de valores singulares de  $A$ . As colunas de  $U$  são chamadas de vetores singulares à esquerda e as colunas de  $V$  de vetores singulares à direita. O produto  $U\Sigma V^T$  é denominado uma **SVD** de  $A$ .

Cada uma das matrizes envolvidas possui propriedades específicas que desempenham um papel crucial na decomposição:

Matriz  $U$ :

- As colunas de  $U$  são autovetores de  $AA^T$ .
- $\det(U) = \pm 1$
- $U^{-1} = U^T$
- $U$  forma uma base ortogonal para o espaço das colunas de  $A$ .

Matriz  $\Sigma$ :

- Os valores singulares  $\sigma_i$  são raízes quadradas dos autovalores de  $A^T A$ .
- A matriz  $\Sigma$  é diagonal, o que significa que todos os seus elementos fora da diagonal principal são zero.
- Os elementos da diagonal principal de  $\Sigma$ , denotados como  $\sigma_1, \sigma_2, \dots, \sigma_r$ , são os valores singulares de  $A$ , onde  $r$  é o posto da matriz  $A$ . Esses valores são dispostos em ordem decrescente:  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r \geq 0$ .
- A matriz  $\Sigma$  terá  $\min(m, n)$  valores singulares, onde os valores além do posto da matriz (se houver) são zero.

Se  $A$  é uma matriz  $m \times n$ :

- $\Sigma$  terá  $m$  linhas e  $n$  colunas.
- Se  $m > n$ ,  $\Sigma$  terá  $n$  valores singulares seguidos de  $m - n$  zeros.
- Se  $m < n$ ,  $\Sigma$  terá  $m$  valores singulares seguidos de  $n - m$  zeros.

Matriz  $V$ :

- $\det(V) = \pm 1$
- $V^{-1} = V^T$
- $V$  forma uma base ortogonal para o espaço das linhas de  $A$ .
- A matriz  $V$  é construída a partir de um conjunto ortonormal de autovetores da matriz  $A^T A$ .

As matrizes  $U$  e  $V$  são ortogonais, ou seja:

$$A^{-1} = A^T \iff AA^T = I$$

- Para a construção de  $\Sigma$  na fatora  o, temos que encontrar os autovalores da matriz  $(A^T A)$ , ordenamos esses autovalores do maior para o menor, denotamos como:

$$\sigma_1^2 \geq \sigma_2^2 \geq \dots \geq \sigma_k^2 > \sigma_{k+1}^2 = \dots = \sigma_n^2 = 0$$

onde  $\sigma_k^2$     o menor autovalor maior que 0 de  $A^T A$ .

A matriz diagonal  $\Sigma$     dada por:

$$\Sigma = \begin{bmatrix} \sigma_1 & 0 & \dots & 0 \\ 0 & \sigma_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_n \\ 0 & 0 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 0 \end{bmatrix}$$

onde  $\sigma_i = 0$  quando  $k < i \leq n$ . Os valores singulares são únicos para cada matriz  $A$ .

- Para a construção da matriz ortogonal  $V$ , usamos a matriz simétrica  $A^T A$ , fatoramos ela como:

$$A^T A = V D V^T$$

$V$  é uma matriz ortogonal  $n \times n$ . Cujas colunas são chamadas de vetores singulares direitos, as colunas são os autovetores de  $A^T A$ . Os vetores singulares direitos formam uma base ortonormal para o espaço linha de  $A$ .

- Os elementos de  $U$  são determinados por

$$u_i = \frac{1}{\sigma_i} A v_i, \quad i = 1, 2, \dots, n$$

$U$  é uma matriz  $m \times m$ , onde as colunas são chamadas de vetores singulares esquerdos, os vetores singulares esquerdos representam uma base ortonormal para o espaço da coluna de  $A$ .

Determinamos os autovetores de  $A A^T$ , as colunas desses autovetores formam a matriz  $U$ . É comum selecionar os autovetores correspondentes aos maiores autovalores para as primeiras colunas de  $U$ . Para termos a garantia de que  $U$  é ortogonal nós normalizamos cada coluna de  $U$  dividindo pela sua norma Euclidiana.

Deste modo, a matriz  $A$   $m \times n$ , com  $n$  valores singulares pode ser escrita na forma:

$$A = \sigma_1 u_1 v_1^T + \dots + \sigma_n u_n v_n^T = \sum_{i=1}^n \sigma_i u_i v_i^T$$

Pode-se implementar um **algoritmo** para a solução de norma mínima para o problema de mínimos quadrados via SVD a partir de:

- Calcular a SVD de  $A$ ;
- Calcular o vetor  $c = U^T b$ ;

- Calcular o vetor  $y = (c_1/\sigma_1, \dots, c_m/\sigma_m)$  (se  $r = m$ ) e  $y = (c_1/\sigma_1, \dots, c_r/\sigma_r, 0, \dots, 0)$  (se  $r < m$ );
- Calcular o vetor  $x = Vy$ .

### O problema de Mínimos Quadrados via SVD

- $Ax = b$  nem sempre tem solução exata.
- O problema de mínimos quadrados consiste em determinar um vetor  $x$  que minimiza a expressão  $\|b - Ax\|_2$ .
- A denominação desse problema se deve ao fato de estarmos minimizando a soma dos quadrados dos resíduos.

A partir disso, temos o **Teorema** a seguir:

Sejam  $A \in \mathbb{R}^{n \times m}$ ,  $b \in \mathbb{R}^n$  ( $m > n$ ) e  $\text{posto}(A) = r$ . O problema de mínimos quadrados associado ao sistema linear  $Ax = b$  possui exatamente uma solução de norma mínima.

A resolução do problema de mínimos quadrados via SVD segue os seguintes passos:

- Cálculo da SVD de  $A$ :

$$A = U\Sigma V^T$$

- Transformação do vetor de respostas:

$$\mathbf{c} = U^T \mathbf{b}$$

- Cálculo do vetor intermediário  $\mathbf{y}$ : Se o posto de  $A$  for  $r$ :

$$y_i = \frac{c_i}{\sigma_i}, \quad i = 1, \dots, r$$

- Determinação da solução:

$$\mathbf{x} = V\mathbf{y}$$

Esse processo resulta na solução de norma mínima para o problema.

## 4. Resultados

A resolução de um problema de regressão linear simples pelo método dos mínimos quadrados via SVD, envolve a construção da matriz de design, a aplicação da decomposição SVD, o cálculo da pseudo-inversa e, finalmente, a multiplicação pela matriz de resultados.

A metodologia foi implementada em linguagem **Julia** para os dados de consumo e renda, segue script abaixo:

## 4.1 Exemplo 1: Relação entre Consumo e Renda

Utilizando dados fictícios de consumo ( $y$ ) e renda ( $x$ ):

$i$	Consumo ( $y$ )	Renda ( $x$ )
1	122	139
2	114	126
3	86	90
4	134	144
5	146	163
6	107	136
7	68	61
8	117	62
9	71	41
10	98	120

Tabela 1: Dados de Consumo e Renda, origem: Wikipedia

Implementação em Julia:

```
## Dados da Tabela
x = [139.0, 126.0, 90.0, 144.0, 163.0, 136.0, 61.0, 62.0, 41.0, 120.0]
y = [122.0, 114.0, 86.0, 134.0, 146.0, 107.0, 68.0, 117.0, 71.0, 98.0]

## Número de observações
n = length(x)

## Construir a Matriz de Design A e o Vetor b
A = hcat(ones(n), x)
b = y

## Realiza a SVD de A
F = svd(A)

## Constrói a matriz Sigma_plus (pseudo-inversa dos valores singulares)
tolerance = max(size(A)...) * eps(Float64) * F.S[1]
Sigma_plus_diag = [s > tolerance ? 1.0/s : 0.0 for s in F.S]

## A pseudo-inversa A_plus
A_plus = F.V * Diagonal(Sigma_plus_diag) * F.U`

## Encontrar os Coeficientes Beta
beta_hat = A_plus * b

println("Coeficientes estimados (beta_0, beta_1):")
println("beta_0 (intercepto) = ", beta_hat[1])
```



```
println("beta_1 (coeficiente de Renda) = ", beta_hat[2])
```

Como mencionado anteriormente, a solução do problema habilita diversas possibilidades para tratativa, há o exemplo de **Previsão**, que pode ser implementado da seguinte maneira:

```
## Função para prever consumo
function predict_consumption(renda)
    return beta_hat[1] + beta_hat[2] * renda
end

## Coeficientes estimados (beta_0, beta_1):
beta_0 (intercepto) = 52.69018446221764
beta_1 (coeficiente de Renda) = 0.4954054002447952

predicted_y = predict_consumption(100.0)
println("Consumo previsto para Renda = 100: ", predicted_y)

## Estimativa para a população do Brasil em 2025 (exemplo anterior)
println("Estimativa em 2025: ", predict_consumption(2025.0))

## Consumo previsto para Renda = 100: 102.23072448669716
## Estimativa em 2025: 1061.2185590924962
```

Coeficientes estimados:  $\beta_0$  (intercepto) = 52.69018446221764  $\beta_1$  (coeficiente de Renda) = 0.4954054002447952

Resultado:

$$\hat{\beta}_0 \approx 52.69, \quad \hat{\beta}_1 \approx 0.4954$$

# 4.2 Exemplo 2: Crescimento Populacional com dados de população ao longo dos anos.

Modelando um crescimento exponencial:

$$P(t) = ae^{bt}$$

Após transformação logarítmica e aplicação da SVD:

```
anos = [2000, 2005, 2010, 2015, 2020]
pop = [1000, 1200, 1450, 1700, 2000]

t = anos .- minimum(anos) # Transformar anos em tempo relativo
y_log = log.(pop) # Transformar população para log
```

```

A_exp = hcat(ones(length(t)), t) # Matriz de design para o modelo linearizado
U, S, Vt = svd(A_exp)

tolerance_exp = max(size(A_exp)...) * eps(Float64) * S[1]
Sigma_plus_exp_diag = [s > tolerance_exp ? 1.0/s : 0.0 for s in S]
A_plus_exp = Vt * Diagonal(Sigma_plus_exp_diag) * U'

x_coeffs = A_plus_exp * y_log
c0, c1 = x_coeffs

a_exp = exp(c0) # Voltar para a escala original para 'a'
b_exp = c1      # 'b' permanece o mesmo

println("Coeficientes do modelo exponencial:")
println("a = ", a_exp)
println("b = ", b_exp)

```

Coeficientes do modelo exponencial: a = 998.6749007624955 b = 0.0354143423719998

## 5. Conclusão

O problema dos mínimos quadrados discretos, ao buscar minimizar a soma dos quadrados dos resíduos, apresenta diferentes estratégias de solução. Dentre elas, a Decomposição em Valores Singulares (SVD) destaca-se pela robustez numérica, tornando-se especialmente vantajosa em situações de colinearidade ou dados mal-condicionados.

Através de exemplos práticos, foi possível demonstrar como a SVD permite obter soluções estáveis e interpretar geometricamente a estrutura dos dados. O uso da linguagem Julia, com seu suporte eficiente a operações matriciais, também contribuiu para a aplicabilidade computacional dos métodos discutidos.

Como possíveis desdobramentos, recomenda-se explorar abordagens baseadas em regularização, como Ridge Regression ou métodos iterativos, para comparação dos métodos, e a aplicação para resolução de problemas específicos e definidos, por exemplo, otimização de carteiras de seguros, utilizando otimização estocástica.

Dentre as dificuldades encontradas durante o desenvolvimento do trabalho, houve a dificuldade de compreensão de conceitos matemáticos, até então novos que exigiram estudos de diferentes maneiras, sejam por leitura, vídeo-aulas, e a busca para encontrar bibliografia que apresentasse definições formais. Além disso, a formatação desse documento se mostrou desafiadora, até então, era uma maneira desconhecida, mas se apresentou muito prática utilizando recursos do LaTeX via documentos qmd, digitados na IDE RStudio

## 6. Referências bibliográficas

STRANG, Gilbert. Álgebra Linear e suas Aplicações. Tradução da 4ª ed. norte-americana. São Paulo: Cengage Learning, 2010.

DECOMPOSIÇÃO EM VALORES SINGULARES. In: WIKIPÉDIA: a enciclopédia livre. [S.l.]: Wikimedia Foundation, [s.d.]. Disponível em: [\\url{https://pt.wikipedia.org/wiki/Decomposi%C3%A7%C3%A3o\\_em\\_Valores\\_Singulares}](https://pt.wikipedia.org/wiki/Decomposi%C3%A7%C3%A3o_em_Valores_Singulares). Acesso em: 23 jun. 2025.

MÉTODO DOS MÍNIMOS QUADRADOS. In: WIKIPÉDIA: a enciclopédia livre. [S.l.]: Wikimedia Foundation, [s.d.]. Disponível em: [\\url{https://pt.wikipedia.org/wiki/M%C3%A9todo\\_dos\\_m%C3%ADnimos\\_quadrados}](https://pt.wikipedia.org/wiki/M%C3%A9todo_dos_m%C3%ADnimos_quadrados). Acesso em: 23 jun. 2025.